

TAPI • NVIDIA Startup AI Radar

Mapear, diagnosticar e prescrever a stack NVIDIA para startups AI-native brasileiras

Plataforma multi-agente com diagnóstico técnico próprio (AIMI), evidência rastreável dos dois lados e ROI de graduação — rodando na própria stack que recomenda.



"Wrapper" não é o ponto — o espaço em branco é diagnóstico

Sourcing hoje = firmographics + funding. O TAPI compete em profundidade de diagnóstico técnico.

- Harmonic · Specter · Tracxn · PitchBook · CB Insights são bases de **quem captou, de quem, quando** — dinheiro e time.
- Nenhuma faz **diagnóstico técnico de maturidade de IA + prescrição de stack com evidência + ROI**.
- O TAPI disputa o eixo do Inception: **quão AI-native, e o quanto a NVIDIA acelera a graduação da stack**.
- É um produto de **apoio à decisão (DSS)** — não mais um diretório.

Em destaque

Resposta à crítica do wrapper de LLM: **o TAPI não é wrapper** — o valor está na orquestração, no dataset, no RAG com evidência e no recommender.

E ele **roda na própria stack que recomenda** (Nemotron + NeMo Retriever + NIM): dogfooding.

Arquitetura

API e worker separados — um run faz coleta de rede + 3–4 chamadas de LLM; não cabe em request síncrono.

Stack

Python 3.12 · TypeScript

FastAPI · SSE · Pydantic v2

LangGraph + checkpointer

Nemotron — 2 perfis

Nano planner · roteio

Super extração · diag.


Qdrant · BM25 · RRF

NeMo Retriever (embed/rerank)

PostgreSQL · SQLAlchemy


Redis + RQ · worker

Next.js · React · Tailwind



O grafo multi-agente — 10 nós (LangGraph)

Cada nó é uma função `GraphState → update parcial`; o grafo mescla e passa adiante.



Em destaque

evidence_validator é a única bifurcação: aplica a regra de N fontes (hosts distintos). Insuficiente + orçamento → volta ao **scraper**; suficiente → segue ao RAG; retry esgotado → corta para um briefing terminal "dados insuficientes" (sem inventar). Roteia por Command — contador e rota da mesma fonte de verdade.

AIMI — o índice próprio (0–100, 4 pilares de 0–25)

Definição estável (referência de rotulagem); heurística evolutiva. Cada sub-score > 6 exige evidência citada.

P1 — Data Moat

Dados proprietários e feedback loops defensáveis. Mede defensabilidade.

P2 — Workflow Depth

Automação multi-passo, agentes, integrações. → NeMo Guardrails / orquestração.

P3 — Technical Optimization ★

Gatilho primário. Serving/fine-tuning próprio vs. API crua. → NIM · TensorRT-LLM · Triton · RAPIDS.

P4 — Distribution & Moat

GTM, integração enterprise, lock-in. → NVIDIA AI Enterprise / Inception.


Em destaque

A trava de evidência mora **no próprio tipo**: é impossível um PillarScore > 6 sem ao menos uma evidência. Defesa em profundidade — schema, nó e guardrail.

P3 baixo dispara as recomendações de graduação e é o que o GPU Graduation Engine quantifica em ROI.

"Wrapper" não é classe — é uma região do plano

Dois eixos sem confundir: a **classe** (papel da IA) e o **AIMI** (maturidade).



As cinco regiões

- **Alvo de graduação ★** — AI-native, P1/P2 alto e **P3 baixo**: maior upside NVIDIA, topo da fila.
- **Wrapper frágil** — AI-native, baixo em ~todos os pilares: risco de substituição.
- **Maduro / defensável** — alto em tudo: foco em comunidade/enterprise (P4).
- **Periférico** — AI-enabled: baixa prioridade (IA não é o núcleo).
- **Fora de escopo** — non-AI: briefing terminal.

Toda recomendação exige evidência dos dois lados

Faltando um dos lados, a recomendação não pode existir.

lado startup

evidencia_gap

o gap do AIMI — onde a empresa precisa graduar.

lado NVIDIA

evidencia_nvidia

a citação rastreável da KB — qual tech resolve.

redação


o LLM só escreve

a evidência nunca vem do modelo.

- Reforçado em **3 camadas**: o schema (Pydantic), o nó recommender e o guardrail (NeMo Guardrails no briefing).
- Cada Evidence carrega **URL · trecho · fetched_at · hash · política de ToS** — auditável célula a célula.

RAG NVIDIA híbrido — evidência citável do lado NVIDIA

Não é busca genérica: parte dos **gaps do AIMI** (P3 sempre primeiro quando é gap).



Em destaque

KB curada (manifesto + conteúdo separados, sem drift). O "grounding" conceitual (rubrica AIMI) é **filtrado** do retrieve — vira definição, não tech recomendável.

Reranker decidido **com dados**: NeMo (grátis, dogfood) empata com Cohere no ruído.

Do diagnóstico à decisão — DSS de 3 níveis

O índice alimenta o recommender; não é decoração.

nível 1

Recomendação

gaps da startup × evidência NVIDIA → as techs certas, com ROI quando há graduação.

nível 2

Inception Priority

potencial AI-native × upside NVIDIA — alto P1/P2 com P3 baixo = topo do outreach.

nível 3

Radar de coorte

clustering (cuML/GPU) → o ecossistema agrupado por perfil e prontidão de graduação.

GPU Graduation Engine — a matriz de benchmark vira a estimativa de ROI de servir o modelo na GPU própria (API externa → stack otimizada). É a ponte concreta entre "você é um wrapper" e "eis quanto economiza graduando".

Real atrás de flag — o default offline é só o CI

Cada peça de rede/LLM/GPU tem substituto offline determinístico; o real é plugável por flag.

— O **diagnóstico/evidência** vêm da espinha determinística; o LLM **só toca a redação**.

— Onde o LLM muda o resultado (classificação, briefing), medimos o **real ao vivo**; onde não muda, ficamos no determinístico e explicamos.

— Qualquer falha de LLM (inclusive timeout) **degrada limpo** para o determinístico
— o run nunca trava.

Dogfooding — a stack que recomenda

Nemotron Nano / Super via `build.nvidia.com`

(NIM)

NeMo Retriever embed + rerank

NeMo Guardrails rail de evidência

RAPIDS / cuML coorte em GPU

Triton • TensorRT-LLM alvo + ROI

Decisões de stack — e o porquê

Eixo	Decisão	Razão
Cérebro dos agentes	 NVIDIA Nemotron (Nano/Super)	Dogfooding · reasoning toggle · grátis
Orquestração	 LangGraph + checkpointer + interrupts	Retry, resume e HITL por run_id
Vector DB	 Qdrant (denso + BM25 nativo)	Híbrido nativo, named vectors
Embeddings / rerank	 NeMo Retriever (Cohere no comparativo)	Multilíngue PT-BR · grátis · plugável
Guardrails	 NeMo Guardrails no briefing	On-narrative · evita rec. alucinada
Data eng (GPU)	 RAPIDS/cuDF + cuML	Usa GPU, on-narrative, alimenta o índice
Fila / observabilidade	 Redis + RQ · Langfuse	Pipeline longo · depuração multi-agente

Avaliação — resultados x metas

32 entradas = 24 fixtures sintéticas + 8 empresas reais BR revisadas. Cada métrica reprodutível por um comando.

Métrica	Meta	Resultado
Classificação · macro-F1	≥ 0,75	0,875 fixtures · 0,720 reais — AI-native recall 0,96 ⚠
AIMI · Spearman vs. rótulos	≥ 0,70	0,705 (n=32, sobre evidência completa) ✓
Recomendação · recall@ALTA	≥ 0,70	0,97 geral · 1,00 alvo+wrapper+periférico ✓
Recomendação · evidência 2 lados	= 1,00	1,00 (invariante duro) ✓
RAG · RAGAS faithfulness	≥ 0,80	1,00 · context recall 0,74 (reranker NeMo) ✓
Briefing · faithfulness do texto	≥ 0,80	0,870 (mín. 0,786) ✓
Reranker · NeMo x Cohere	decidir c/ dados	empate no ruído (n=7) — NeMo grátis vence no custo ✓

Limitações honestas

Metas abaixo do alvo são reportadas — não escondidas.

classificação

AI-enabled com n=6 derruba o macro-F1 (0,875→0,720): com 6 exemplos cada erro custa caro. Custo honesto de sair do sintético — **AI-native segue em 0,96.**

dados

Curadoria das 8 reais é light: verificação + correção, não rotulagem do zero. 3 linhas guardam resíduo circular na correlação AIMI.

avaliação

Juiz LLM da RAGAS bloqueado pelo ambiente (conflito de dependências) — vale o proxy léxico + o ganho do reranker real.

ROI / GPU

ROI/GPU não é medição ao vivo: depende de serving GPU; o briefing sai sem ROI por padrão. Coorte entregue em CPU (qualidade de demo).

Consulta ao vivo — pipeline multi-agente + HITL

Domínio da startup → a escada de nós marca ✓ um a um (SSE) → o run pausa no painel **Revisão humana** → "Aprovar e retomar".

[inserir GIF aqui]

Briefing em PDF — evidência rastreável dos dois lados

Diagnóstico AIMI → recomendações com o **gap da startup** + a **citação NVIDIA** lado a lado → ROI quando há graduação.

[inserir GIF aqui]

Radar de coorte — o ecossistema como portfólio

Scatter classe × AIMI, clusters do DSS nível 3, ordenação por **Inception Priority**. Filtros por setor / maturidade / classe.

[inserir GIF aqui]

Próximos passos

Não são ideias soltas — é a continuação direta do que já está medido (e das limitações).

coorte

Coorte em volume — de dezenas para centenas de startups; é o que destrava a qualidade real do radar de coorte (nível 3).

GPU

Serving em GPU própria — liga o ROI ao vivo no briefing; o GPU Graduation Engine sai de trás da flag.

RAGAS

Juiz LLM da RAGAS — resolver o conflito de ambiente e fechar a avaliação de RAG ponta a ponta.

curadoria

Curadoria independente das empresas reais — eliminar o resíduo circular da correlação AIMI.



Obrigado

TAPI · NVIDIA Startup AI Radar — multi-agente, evidência rastreável, dogfooding.

LinkedIn · [/in/antoniotra](#)

GitHub · [antonioatra/case_NVIDIA](#)

